

H1 / H1b — Guía de estudio

El modelo, la construcción de los indicadores y la interpretación de los resultados

Documento de apoyo personal para repasar antes de la comisión — no es parte del cuerpo formal de la tesis.

Este documento explica, paso a paso, qué está pasando en el modelo que sostiene **H1** y **H1b**: por qué está armado como está, qué mide cada indicador, y cómo leer los coeficientes que salieron significativos. La idea es que después de leerlo puedas explicar el modelo con tus propias palabras, sin depender de la slide.

H1

Se conoce a más gente en ocupaciones con habilidades parecidas a las propias, más allá del prestigio.

H1b

Esa homofilia de habilidades varía según el nivel educativo del ego.

Resultado en una línea: ambas se sostienen con la especificación basada en red (SH_{ip}^{red}): la similitud de habilidades predice conocidos controlando por prestigio (H1), y ese efecto es distinto según el nivel educativo del ego (H1b).

1. La estructura de los datos: por qué 26.325 filas

El generador de posiciones (Lin & Dumin, 1986) le pregunta a cada ego si conoce a alguien en cada una de las 27 ocupaciones del generador (Q0101 a Q0127). Eso significa que **cada ego aporta hasta 27 filas** a la base de datos del modelo, una por cada posición — no una fila por persona.

Ego	Posición (p)	¿Conoce? (n_conocidos)
Ego 001	Q0101 — Gerentes/as grandes empresas	2
Ego 001	Q0102 — Profesores/as ed. media o básica	5
Ego 001	... (27 filas en total)	...
Ego 002	Q0101 — Gerentes/as grandes empresas	0
Ego 002	Q0102 — Profesores/as ed. media o básica	3
Ego 002	... (27 filas en total)	...

975 egos × 27 posiciones = **26.325 díadas ego-posición**. Este formato se llama *base larga* (long format): la unidad de análisis del modelo no es la persona, es el par ego-posición.

2. Por qué el modelo es “multinivel”

El problema con esas 26.325 filas es que **no son 26.325 observaciones independientes**. Las 27 filas del Ego 001 comparten todo lo propio de esa persona: su educación, su edad, cuánta gente conoce en general. Si el modelo tratara esas 27 filas como si vinieran de 27 personas distintas, estaría inflando artificialmente el tamaño de la muestra — y subestimando el error estándar de los coeficientes, lo que puede hacer que algo parezca significativo cuando en realidad no lo es tanto.

Analogía: el salón de clases

Es el mismo problema que tener alumnos agrupados en salones de clase: los 30 alumnos de un mismo salón no son 30 observaciones independientes entre sí (comparten profesor, comparten ambiente), así como los alumnos de otro salón tampoco lo son entre ellos. Un modelo multinivel le da a **cada salón** (aquí, cada ego) **un ajuste propio** — un intercepto individual, u_i — estimado a partir de sus propias 27 respuestas, en vez de mezclarlo todo en una sola bolsa.

El intercepto aleatorio u_i

Es la propensión propia de cada ego a reportar conocidos, más allá de lo que explican SP_{ip} , SH_{ip}^{red} y el resto de los predictores. Un ego muy sociable en general tendrá un u_i alto en todas sus 27 filas; uno más reservado, un u_i bajo. El modelo asume que esos 975 valores de u_i vienen de una distribución normal centrada en cero.

3. Por qué “binomial negativa” y no una regresión lineal común

La variable a explicar ($n_conocidos$, recodificada en tramos) es un **conteo**: 0, 1, 2, 3 conocidos, etc. — nunca valores negativos, nunca decimales. Una regresión lineal común (OLS) asume que la variable puede tomar cualquier valor real y que su varianza es constante; ninguna de las dos cosas es cierta para un conteo.

Además, este tipo de conteos sociales suele estar **sobredisperso**: su varianza es mayor que su promedio (mucha gente con 0-1 conocidos, pero una cola larga de personas con muchísimos). Un modelo de Poisson asume que $\text{varianza} = \text{promedio}$, así que subestima los errores estándar cuando hay sobredispersión. La **binomial negativa** agrega un parámetro extra (θ , theta) que absorbe exactamente ese exceso de varianza.

4. La ecuación formal, término por término

Con lo anterior, la ecuación completa del modelo queda así. No hace falta memorizarla de memoria: lo importante es poder señalar cada pieza y decir qué hace.

$$\log(\mu_{ip}) = \beta_0 + \beta_1 SP_{ip} + \beta_2 SH_{ip}^{red} + \beta_3 Educ_i \\ + \beta_4 (SH_{ip}^{red} \times Educ_i) + \beta_5 TamGrupo_p + \beta_6 Sexo_i + \beta_7 Edad_i + u_i$$

$$conteo_{ip} \sim \text{BinomNeg}(\mu_{ip}, \theta) \quad u_i \sim N(0, \sigma_u^2)$$

Término	Qué es
i, p	i indexa al ego; p indexa la posición del generador (1 a 27)
μ_{ip}	Número esperado de conocidos del ego i en la posición p
β_0	Intercepto: valor base del modelo cuando todos los predictores están en su nivel de referencia
$\beta_1 \dots \beta_7$	Coefficientes de cada predictor — cuánto cambia $\log(\mu_{ip})$ por cada unidad del predictor
SP_{ip}	Similitud de prestigio ego-posición (ver Sección 5)
SH_{ip}^{red}	Similitud de habilidades ego-posición, versión de red (ver Sección 5)
$SH_{ip}^{red} \times Educ_i$	Interacción: permite que el efecto de la similitud de habilidades cambie según la educación del ego — es el término que responde H1b
$TamGrupo_p$	Tamaño del grupo ocupacional de la posición p (share de la PEA en ISCO-08)
u_i	Intercepto aleatorio por ego (Sección 2)
θ (theta)	Parámetro de sobredispersión de la binomial negativa (Sección 3)

5. Cómo se construyen SP_{ip} y SH_{ip}^{red}

Los dos indicadores centrales del modelo miden lo mismo en principio — “¿qué tan parecida es la posición p a la ocupación del ego?” — pero sobre dos dimensiones distintas: prestigio y habilidades. Ambos están contruidos como distancias **invertidas** (con signo negativo), así que en los dos casos **un valor más alto (más cercano a 0) significa más similitud**.

SP_{ip} — similitud de prestigio

$$SP_{ip} = - | ISEI_i - ISEI_p |$$

Distancia en puntos ISEI (Ganzeboom, 2010) entre el ISEI de la ocupación del ego y el ISEI de la posición p, con el signo invertido. Si ambas ocupaciones tienen el mismo ISEI, $SP_{ip} = 0$ (similitud máxima); mientras más distintas en prestigio, más negativo.

SH_{ip}^{red} — similitud de habilidades, en red

$$SH_{ip}^{red} = - \frac{1}{|C_i| |C_p|} \sum_{a \in C_i} \sum_{b \in C_p} d_{\phi}(a, b)$$

C_i es el conjunto de categorías de habilidad esenciales ($RCA > 1$) de la ocupación del ego; C_p , el de la posición p. $d_{\phi}(a, b)$ es la distancia geodésica entre las categorías a y b **sobre la misma red de complementariedad ϕ que produce las 4 comunidades Leiden** (peso de arista = $1 - \phi$, así que categorías muy complementarias quedan “cerca” en la red). SH_{ip}^{red} promedia esa distancia entre todos los pares posibles de categorías de ego y de la posición, y la invierte.

¿Por qué red y no el CA (Análisis de Correspondencias)?

El indicador original de la tesis (SH_{ip}) usaba coordenadas del CA. SH_{ip}^{red} usa en cambio la misma estructura de red que ya sostiene el hallazgo de comunidades (bio-ambiental-legal): así el indicador de homofilia de H1/H1b queda construido sobre la misma geometría que el resto del argumento estructural de la tesis, en vez de una reducción dimensional distinta.

SH_{ip}^{com} — similitud por perfil de comunidad (chequeo de sensibilidad)

$$SH_{ip}^{com} = \frac{\vec{s}_i \cdot \vec{s}_p}{|\vec{s}_i| |\vec{s}_p|}$$

Similitud de coseno entre el vector de 4 shares de comunidad (share_com1..4) del ego y el de la posición. Es la misma idea que SH_{ip}^{red} , pero colapsando las 110 categorías de habilidad a solo 4 números — se usa como chequeo de que el resultado no depende de los detalles finos de la red.

6. La tabla de resultados completa

Los seis modelos comparten los mismos controles (SP_{ip} , educación, tamaño del grupo ocupacional, sexo, edad) y van agregando el indicador de habilidades. Los tres primeros usan SH_{ip}^{red} (especificación principal); los últimos dos, SH_{ip}^{com} (sensibilidad).

Predictor	M0: solo prestigio	M1: + hab. red (H1)	M2: + interac. educ. (H1b)	M1 com. (sensib.)	M2 com. (sensib.)
SP_{ip}	0,021***	0,018***	0,018***	0,019***	0,019***
SH_{ip}^{red}	—	1,147***	2,576***	—	—
Educación	0,144***	0,134***	-0,143**	0,142***	0,236***
Habilidades × educ.	—	—	-0,227***	—	-0,130***
SH_{ip}^{com}	—	—	—	0,427***	1,250***
Tamaño grupo ocup.	7,224***	8,721***	7,984***	6,761***	6,189***
Sexo (mujer)	0,040 (n.s.)	0,034 (n.s.)	0,036 (n.s.)	0,029 (n.s.)	0,029 (n.s.)
Edad	0,003 (n.s.)	0,002 (n.s.)	0,003 (n.s.)	0,003 (n.s.)	0,003 (n.s.)
Intercepto	-0,741***	0,653***	2,409***	-1,075***	-1,663***
N (díadas)	26.379	26.325	26.325	26.325	26.325
R^2 marginal	0,139	0,146	0,152	0,143	0,149
R^2 condicional	0,378	0,387	0,393	0,383	0,388

*** $p < 0,001$, ** $p < 0,01$ · binomial negativa multinivel (glmmTMB, family nbinom2), intercepto aleatorio por ego · coeficientes en escala log (ver Sección 7 para cómo leerlos) · fuente: R5_similitud_habilidades_red_vs_ca.R, Sección 7.

Pendiente de verificar

Estos coeficientes vienen de una reconstrucción de la fórmula del modelo (script de robustez R5), no de 05_modelos.R directamente — ese script no estaba disponible al construir R5. La escala difiere bastante de la tabla con SH_{ip} (CA) mostrada en la mañana (SP_{ip} pasó de 0,440 a 0,021; educación, de 0,300 a 0,144), lo que sugiere que 05_modelos.R probablemente estandariza los predictores antes de entrar al modelo, o usa alguna otra diferencia de especificación no replicada aquí. La dirección y significancia de los efectos son interpretables tal como están; las magnitudes exactas deben cotejarse contra el script real antes de reportarlas como definitivas.

7. Cómo leer un coeficiente en este modelo (escala log)

El modelo usa un **enlace logarítmico** (log-link): no está prediciendo directamente el número de conocidos, sino el *logaritmo* del número esperado de conocidos. Eso significa que los coeficientes no se leen como “+1 unidad del predictor = + β conocidos”, sino en términos **multiplicativos**.

La regla general

$$\frac{\mu_{ip}(x+1)}{\mu_{ip}(x)} = e^{\beta}$$

Por cada unidad que aumenta un predictor x (manteniendo todo lo demás constante), el número esperado de conocidos se multiplica por e^{β} — no se le suma β .

Ejemplo concreto, con SP_{ip}

El ISEI (Ganzeboom) va aproximadamente de 10 a 90 puntos, así que la distancia entre dos ocupaciones puede llegar a unos 80 puntos. Con $\beta(SP_{ip}) = 0,018$ (M1), moverse de la distancia máxima posible (ego y posición en extremos opuestos de prestigio) a distancia cero (misma ocupación) multiplica el número esperado de conocidos por $e^{0,018 \times 80} \sim e^{1,44} \sim \mathbf{4,2 \text{ veces}}$. Es un efecto grande acumulado sobre todo el rango de la variable, aunque el coeficiente por sí solo (0,018) parezca chico.

Por qué no comparar $1,147 (SH_{ip}^{red})$ con $0,018 (SP_{ip})$ directamente

Un coeficiente más grande **no** significa un efecto más fuerte si las dos variables no están en la misma escala. SP_{ip} se mide en puntos ISEI (rango ~ 0 a ~80); SH_{ip}^{red} se mide en distancias geodésicas de red, una escala mucho más chica y en unidades muy distintas. Para comparar cuánto “pesa” cada indicador en términos relativos habría que estandarizar ambos (z-score) antes de correr el modelo — algo pendiente de hacer, no algo que estos coeficientes ya muestren. Lo que sí es directamente comparable, sin estandarizar, es el **signo** y la **significancia** de cada uno.

8. Interpretación de cada resultado significativo

SP_{ip} — significativo y estable en todos los modelos (~0,018-0,021***)

La homofilia de prestigio existe y no desaparece al agregar habilidades: se sigue conociendo más gente en ocupaciones de prestigio parecido al propio, controlando por todo lo demás. Esto es el punto de partida clásico de la literatura (Lin, McPherson) que la tesis busca complementar, no reemplazar.

SH_{ip}^{red} — significativo en M1 (1,147***) H1 se sostiene

Más allá del prestigio, la similitud de habilidades predice independientemente cuántos conocidos reporta un ego en una posición. Que SP_{ip} se mantenga prácticamente igual al agregar SH_{ip}^{red} (0,021 → 0,018) es la evidencia clave de que ambos indicadores están midiendo cosas distintas: si SH_{ip}^{red} fuera solo prestigio disfrazado, SP_{ip} habría caído mucho más al incluirla.

Interacción $SH_{ip}^{red} \times$ Educación — significativa en M2 (-0,227***) H1b se sostiene

El efecto de la similitud de habilidades sobre el número de conocidos **no es igual en todos los niveles educativos** — el signo negativo sugiere que la homofilia de habilidades es más marcada en niveles educativos más bajos y se atenúa a medida que aumenta la educación del ego (una lectura sustantiva posible: a mayor educación, las redes se diversifican más allá del propio nicho de habilidades — conviene pensar esta interpretación con calma antes de fijarla como definitiva).

Educación — coeficiente cambia de signo en M2 (0,134*** → -0,143**): artefacto, no reversión

En M0 y M1, más educación se asocia con más conocidos en general (0,134-0,144***). En M2 aparece negativo porque, al incluir la interacción, el coeficiente de “Educación” ya no representa el efecto promedio de educación: representa el efecto de educación **evaluado en $SH_{ip}^{red} = 0$** . Como SH_{ip}^{red} es una distancia negativa, el valor 0 está fuera del rango real de datos observados — el cambio de signo es un artefacto de no haber centrado la interacción, no una reversión sustantiva del efecto de la educación.

Tamaño del grupo ocupacional — grande y significativo en todos los modelos (~6,2-8,7***)

Es, en gran medida, un efecto casi mecánico: posiciones que representan una porción más grande de la fuerza laboral (más gente trabajando en esa ocupación) tienen, sencillamente, más probabilidad de ser conocidas por cualquier ego — hay más gente ahí para conocer.

Sexo y edad — no significativos en ningún modelo

Ninguno de estos controles predice el número de conocidos por posición una vez que se controla por el resto de las variables del modelo — no hay diferencias sistemáticas de género o edad en la homofilia observada aquí.

Sensibilidad con SH_{ip}^{com} — confirma H1 y H1b (0,427*** y -0,130***)

La versión “gruesa” del indicador (perfil de 4 comunidades en vez de 110 categorías) reproduce la misma dirección y significancia que SH_{ip}^{red} en ambos términos: el resultado no depende de un detalle fino de la red, se sostiene también en la versión más simple del indicador.

9. Qué falta antes de reportar esto como definitivo

- Cotejar la fórmula usada en R5 (Sección 7) contra 05_modelos.R real — en particular, si los predictores están estandarizados (z-score) antes de entrar al modelo, lo que explicaría el cambio de escala frente a la tabla con SH_{ip} (CA).
- Confirmar si el modelo oficial usa pesos muestrales (weight) — R5 no los incluyó.
- Revisar si faltan controles adicionales que sí estaban en 05_modelos.R y no se replicaron en R5.
- Decidir si se reporta SH_{ip}^{red} como especificación principal de H1/H1b en el documento de tesis, o si se mantiene el CA como principal y la red pasa a robustez — la decisión de esta comisión fue usar red como principal.
- Si se reporta la interacción de H1b como hallazgo, centrar SH_{ip}^{red} antes de re-estimar M2, para que el coeficiente de “Educación” sea interpretable como efecto promedio y no como efecto evaluado en un valor fuera de rango.
- 391 ocupaciones del universo RM tienen cobertura de red; el 4,9% de las díadas (1.350 de 27.756) quedó sin SH_{ip}^{red} por caer fuera de esa cobertura — documentar este recorte muestral igual que las demás limitaciones ya declaradas en la tesis.

10. Chuleta rápida para el repaso final

Hipótesis	Estado	Coefficiente clave	Una línea
H1	Se sostiene	$SH_{ip}^{red} = 1,147^{***}$	Habilidades predicen conocidos más allá del prestigio.
H1b	Se sostiene	Interac. = $-0,227^{***}$	La homofilia de habilidades varía según educación (más fuerte en niveles bajos).

Si preguntan “¿por qué multinivel?” → cada ego aporta 27 filas no independientes; el intercepto por ego absorbe esa dependencia. ¿Por qué binomial negativa? → conteo sobredisperso. ¿Por qué cambia el signo de educación en M2? → artefacto de la interacción no centrada, evaluada en $SH_{ip}^{red}=0$ (fuera de rango), no una reversión real.